Redefining xG

Integrazione di Feature Avanzate per Previsioni Informate

Andrea
Capobianco

01

Introduzione

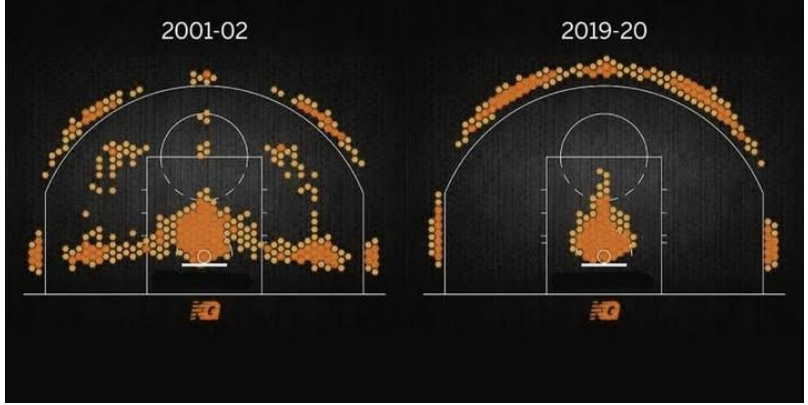

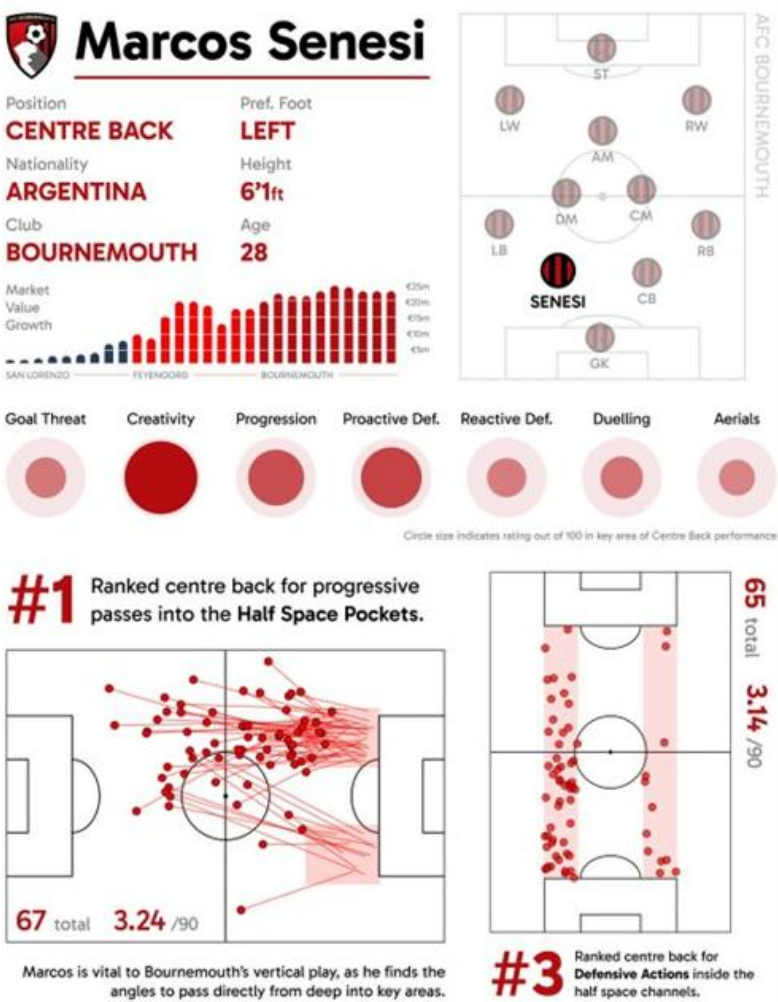

Negli ultimi anni, diversi sport sono stati influenzati dalla **Data Analysis**, al punto in cui, in alcuni sport **lo studio dei dati ha rivoluzionato le strategie di mercato e lo stile di gioco**, permettendo alle squadre di **spendere e giocare in modo intelligente.**

Nel calcio, lo studio dei dati ha portato all'introduzione di diverse **metriche avanzate**, le quali possono portare un **vantaggio competitivo** sulle altre squadre, consentendo di **analizzare in modo più approfondito le prestazioni**, e di **individuare talenti sottovalutati** a basso prezzo.

Expected Goal

- L'***Expected Goal*** (o *xG*) è una statistica che definisce la **probabilità di un certo tiro di scaturire in un goal**
- Può essere visto come una **probabilità condizionale**, che dipende dal **contesto del tiro**
- Questo indice è solo una **previsione**, una **stima**
- L'*xG* permette di definire quanti gol *avrebbero dovuto segnare* le due squadre, **andando oltre al semplice risultato** di una partita, il quale potrebbe spesso dipendere da **episodi** e **casualità**

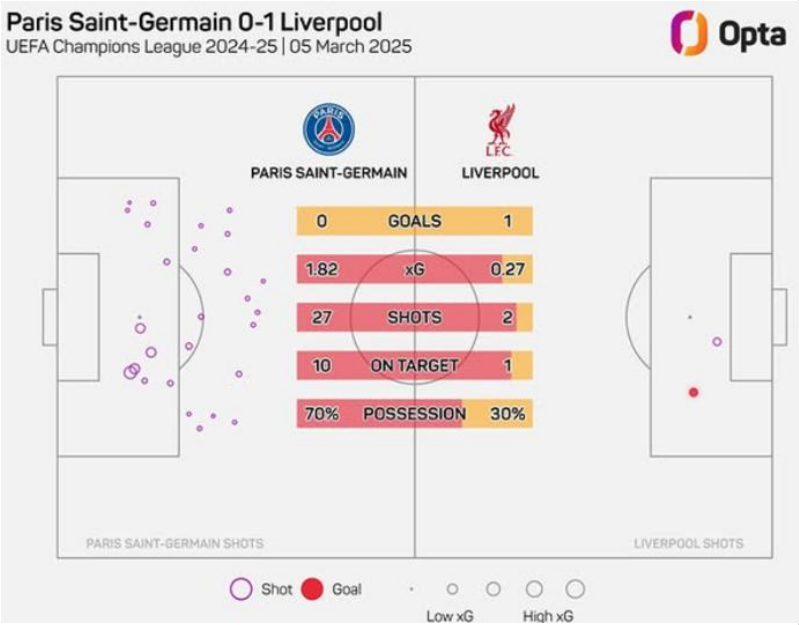

Definizione del Problema

- Gli xG vengono calcolati tramite **modelli statistici**, basati su dataset di centinaia di migliaia di tiri, con diverse feature
- **I modelli attuali falliscono nel catturare il contesto attorno al tiro**, producendo una stima **per il giocatore medio**
  - Il posizionamento degli avversari potrebbe essere determinante
  - Fattori legati alle abilità dei giocatori potrebbero aggiungere informazioni utili
- *Integrare dati relativi ai giocatori e alle squadre coinvolte permetterebbe di ottenere previsioni più accurate?*

02

Implementazione

Dati Utilizzati

- Sono stati raccolti dati relativi ad una singola stagione, per i 5 maggiori campionati europei
  - Serie A (Italia), Premier League (Inghilterra), Bundesliga (Germania), La Liga (Spagna), Ligue 1 (Francia)
- Ogni dataset relativo ad uno specifico campionato include **tra gli 8 e i 10mila tiri**
- Sono stati raccolti dati da diverse fonti (*StatsBomb, FotMob, SoFIFA, ClubElo*), risolvendo anche eventuali differenze di informazioni tra le varie piattaforme

Tipi di Dataset

Baseline

Utilizzato per previsioni semplici, contiene soltanto la **distanza** e l'**angolazione** del tiro

Intermediate

Include molti altri fattori, sia **contestuali** (situazione, parte del corpo) che relativi alle **qualità dei giocatori e delle squadre** coinvolte

Full (Improved)

Include delle feature relative al **posizionamento degli avversari**, andando successivamente (nella versione *Improved*) a quantificare la **distanza** e il **numero** di avversari presenti attorno al tiratore

Tipi di Dataset

Distance	*Angle*
18	19

Minute	*Goal Difference*	*Rating*	*Elo Team*	*Keeper Rating*	*Elo Opponent*	*isHome*	*Position*	*Situation*	*Body Part*
26	3	70	1636	76	1607	True	Forward	Counter	Strong Foot

One on One	*Open Goal*	*Pressure*
False	False	True

Opponents in Cone	*Minimum Distance*
1	1.5

Frame di Tiro

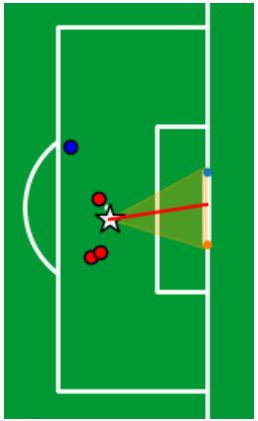


```
{
  "location": [106.0, 45.9],
  "player": {
    "id": 6992,
    "name": "Andrea Masiello"
  },
  "position": {
    "id": 5,
    "name": "Left Center Back"
  },
  "teammate": false
},
{
  "location": [106.9, 38.8],
  "player": {
    "id": 7002,
    "name": "Rafael Tolói"
  },
  "position": {
    "id": 3,
    "name": "Right Center Back"
  },
  "teammate": false
},
{
  "location": [107.0, 45.3],
  "player": {
    "id": 7157,
    "name": "Marco Sportiello"
  },
  "position": {
    "id": 1,
    "name": "Goalkeeper"
  },
  "teammate": false
},
{
  "location": [103.4, 32.6],
  "player": {
    "id": 7033,
    "name": "Nikola Kalinić"
  },
  "position": {
    "id": 23,
    "name": "Center Forward"
  },
  "teammate": true
}
```

Algoritmi e Approcci

- Sono state necessarie diverse operazioni di *preprocessing*, tra cui *normalizzazione* e *One-Hot Encoding*
- Sono stati testati diversi algoritmi, utilizzando sia *reti neurali* che *metodi di ensemble*
    - *Regressione Logistica*, *XGBoost*, *Random Forest*, *AdaBoost*, *LightGBM*, *Multi-Layer Perceptron*
- Su ogni modello è stato effettuato un *parameter tuning* per poter individuare la migliore configurazione possibile, tramite una *Grid Search*, e per testare la stabilità del modello è anche stata utilizzata una *Cross Validation*, dividendo i dati in *fold* in base alle partite, e raggiungendo ottimi risultati in termini di metriche

03

Esperimenti

Prestazioni per Dataset

Il dataset di ogni campionato è stato utilizzato per addestrare un apposito modello, e sono state valutate le *metriche di training*.
Il dataset *full* non porta sempre miglioramenti.
(L'algoritmo *XGBoost* è stato utilizzato per tutti i test)

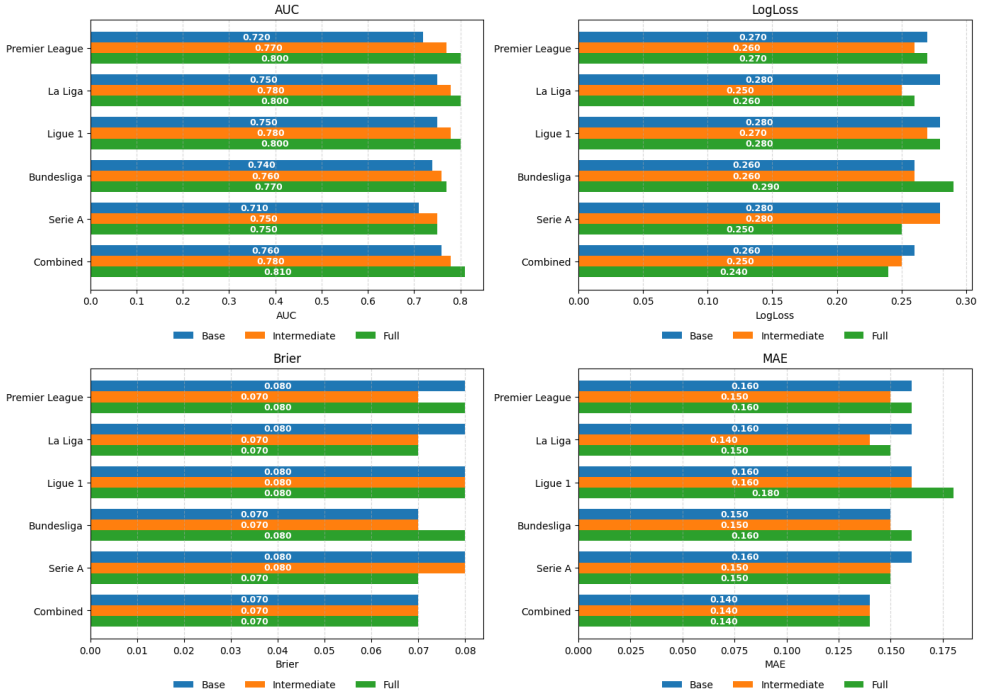

Prestazioni per Dataset

	ENG	ESP	FRA	GER	ITA	Combined
1	Distance	Distance	Distance	Distance	Distance	Distance
2	StrongFoot	Shooter	Head	Head	Head	Head
3	Shooter	Angle	OpenGoal	Angle	Angle	OpenGoal
4	EloOpp.	Head	Angle	Corner	EloTeam	Shooter
5	Angle	OpenGoal	Corner	StrongFoot	FreeKick	Angle
6	Head	EloOpp.	Shooter	EloTeam	StrongFoot	StrongFoot
7	OpenGoal	Keeper	Pressure	Pressure	EloOpp.	Corner
8	Corner	Pressure	Keeper	Shooter	Shooter	FreeKick
9	Minute	StrongFoot	EloOpp.	OpenGoal	Corner	Pressure
10	Pressure	Counter	EloTeam	Counter	Pressure	Counter

Prestazioni per Dataset

	ENG	ESP	FRA	GER	ITA	Combined
1	Distance	Distance	Distance	Distance	Distance	Distance
2	MinDist	OppInCone	OppInCone	OppInCone	OppInCone	OppInCone
3	OppInCone	MinDist	Head	MinDist	MinDist	MinDist
4	Angle	Shooter	MinDist	Head	Angle	Angle
5	EloOpp.	Angle	Angle	Angle	Head	Head
6	StrongFoot	Head	Keeper	StrongFoot	Shooter	StrongFoot
7	Head	EloOpp.	EloTeam	EloTeam	StrongFoot	Shooter
8	Shooter	StrongFoot	Shooter	Counter	EloTeam	keeper
9	Minute	Keeper	StrongFoot	EloOpp.	Keeper	EloTeam
10	EloTeam	Minute	Minute	Forward	EloOpp.	Corner

Prestazioni per Algoritmo

Per ogni algoritmo, è stato addestrato un modello sul dataset TOP5, e si sono osservate le metriche di training.

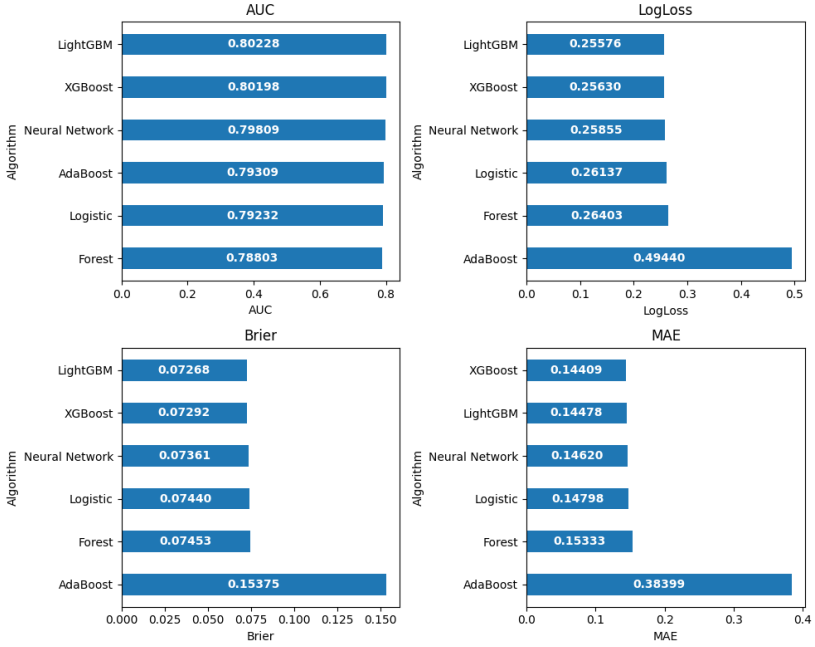

Prestazioni per Algoritmo

Per entrambi gli algoritmi, si è addestrato un modello per ogni campionato (Serie A esclusa) e si sono osservate le metriche di test e i valori di xG predetti. Nonostante il LightGBM sia migliore in termini di metriche con dataset più grandi, **l'XGBoost si rivela più stabile con dataset più piccoli**

Interpretazione del Modello

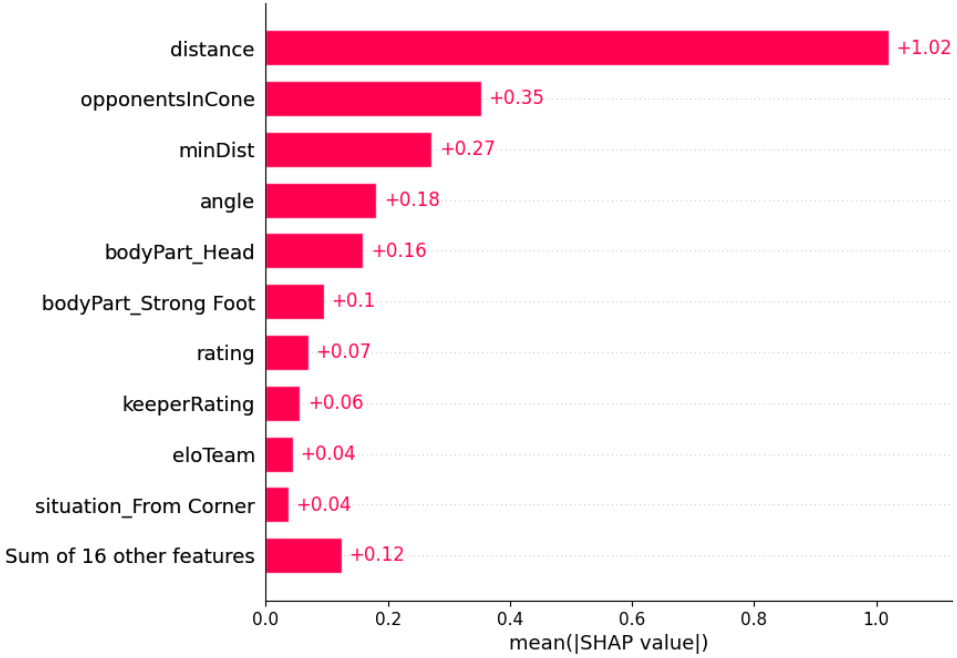

Interpretazione Del Modello

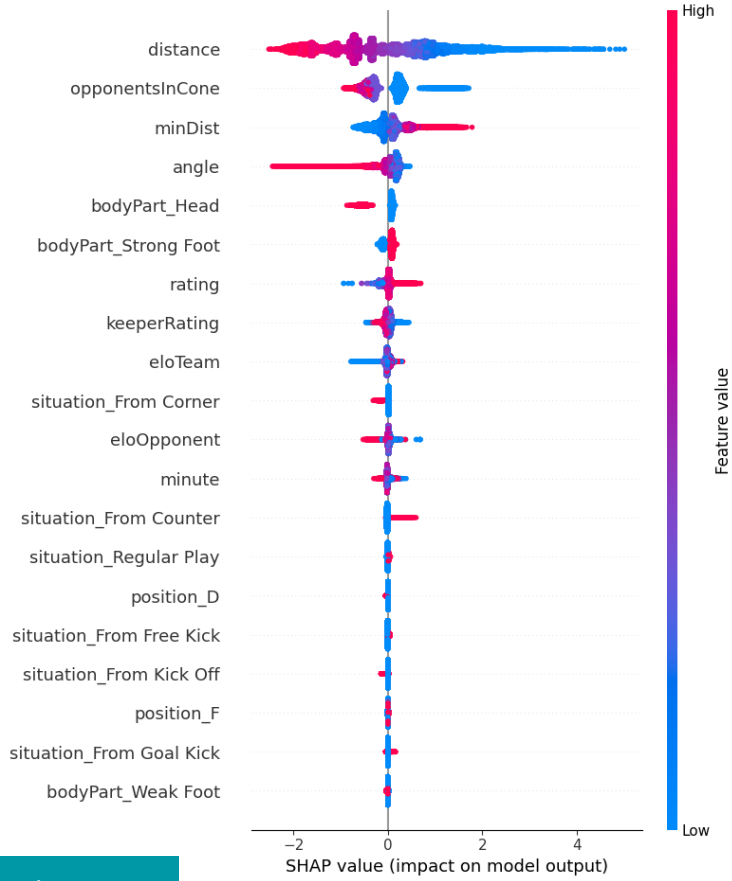

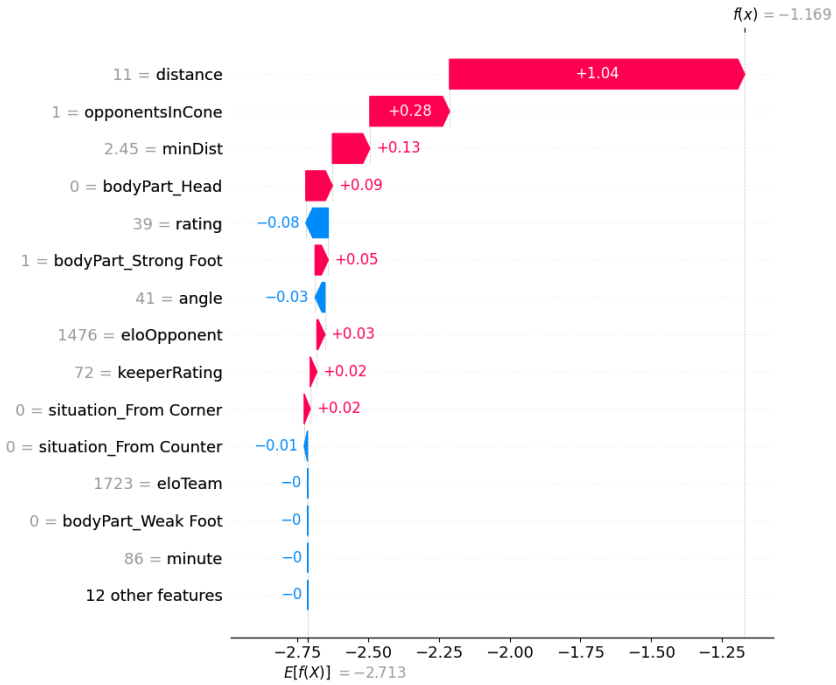

04

Risultati

Confronto tra Modelli e Competitor

Predictions on single shot

Model	*MSE* ↓	*MAE* ↓	R^2 ↑
StatsBomb	**0.06553**	**0.13**	**0.23802**
Full (XGB)	0.06707	0.13739	0.22013
Full (LGBM)	0.06711	0.13739	0.21973
Intermediate	0.06966	0.14462	0.19003

In termini di previsioni sul singolo tiro, i modelli raggiungono **ottimi risultati, non migliori di quelli dei competitor ma vicini**, nonostante i pochi dati e le poche feature a disposizione

Aggregate predictions for single player

Model	*MSE* ↓	*MAE* ↓	R^2 ↑
StatsBomb	0.8588	1.69697	0.85138
Full (XGB)	0.85497	1.73872	0.84772
Full (LGBM)	**0.844**	**1.66607**	**0.85409**
Intermediate	0.89163	1.82071	0.84054

In termini di previsioni aggregate per singoli giocatori, **alcuni modelli performano anche meglio dei competitor**

Conclusioni

- Aggiungere informazioni relative a giocatori e squadre non basta per arrivare a numeri soddisfacenti, poiché **queste feature influenzano i modelli, ma in modo secondario rispetto ad altri fattori**
    - Sono ancora le variabili contestuali (relative alla **posizione del pallone** e al **posizionamento degli avversari**) a determinare maggiormente le probabilità
- Nonostante ciò, è stato dimostrato come **si possano costruire ottimi modelli anche con pochi dati a disposizione**, utilizzando tecniche efficaci, ma soprattutto **feature informative**